

TP 20 — Enquête sur données réelles

Semaine 20 ■ TP-projet noté · Fichiers dans NSI/TP20/ ■ 2 h

Objectifs

- Mener une mini-enquête complète : charger, nettoyer, croiser, trier, présenter
- Fusionner deux tables sur un identifiant commun
- Produire un rendu noté (TP-projet de fin de période)

La mission

Par binômes. Deux fichiers CSV fournis par le professeur (ou téléchargés en début d'heure), liés par un identifiant commun — par exemple : communes + résultats du recensement (code INSEE), ou gares + fréquentation (code gare), ou établissements scolaires + effectifs (code UAI).

Livrable : un fichier `enquete.py` **exécutable de bout en bout** qui affiche votre rapport, et 5 lignes de conclusions en commentaire final.

Partie 1 — Chargement et nettoyage

(30 min)

- Charger les deux tables ; afficher tailles et noms de colonnes.
- Convertir les champs numériques ; écarter (en les comptant !) les enregistrements invalides : champs vides, valeurs hors domaine.
- Vérifier que l'identifiant est sans doublons dans la table de référence (`a_doublons` — semaine 19). Sinon : le signaler et décider quoi faire, par écrit.

Partie 2 — Fusion

(30 min)

- Implémenter `fusion(t1, t2, cle)` du cours (avec l'index en dictionnaire).
- La modifier pour **ignorer en comptant** les enregistrements de `t1` sans correspondant (au lieu de planter) : votre rapport affichera « *n* enregistrements non appariés ».
- Fusionner ; vérifier la taille du résultat.

Partie 3 — L'enquête

(40 min)

Répondre par des requêtes (sélections, agrégations, tris `sorted` + clés — semaines 19-20) à **quatre questions**, dont au moins :

- un **top 10** trié sur un champ de la fusion (impossible sans la fusion : c'est le cœur de l'exercice) ;
- une **moyenne par groupe** (dictionnaire) ;
- une question **de votre choix**, formulée par vous, qui vous intrigue vraiment.

Présentation : titres, f-strings alignées, unités.

Partie 4 — Finitions

(20 min)

Relire : docstrings partout, le script tourne depuis zéro sans intervention, conclusions rédigées (5 lignes : ce que disent les données, ce qui vous a surpris, une limite des données).

Barème (20 points)

Nettoyage : conversions, invalides comptés, doublons vérifiés	5
Fusion correcte avec non-appariés comptés	5
Les 4 requêtes (dont top trié et moyenne par groupe)	6
Présentation du rapport + conclusions	2
Qualité du code (docstrings, fonctions, noms)	2
